

# Documento Técnico, Modelo de Propensión de Compra + Agente IA

Caso Ferreycorp · Abril 2026

## 1. Objetivos

### 1.1 Objetivo de negocio

Desarrollar un sistema que prediga la propensión de compra de un cliente en una visita dada, y permita al equipo comercial **explorar y filtrar** las predicciones en lenguaje natural, sin depender de tableros estáticos ni de equipos de datos para responder preguntas específicas.

### 1.2 Objetivos técnicos

- Construir un modelo de machine learning con AUC-ROC mayor o igual a 0.65 y un **lift @ top-10% mayor o igual a 2.0**.
- Garantizar **explicabilidad** de las predicciones a nivel global (SHAP) y por cliente.
- Ofrecer una **arquitectura de acceso rápido** (menos de 100ms por consulta) para el agente.
- Diseñar la solución **portable entre nubes** (DigitalOcean, AWS, GCP) sin reescribir código.

## 2. Arquitectura de la solución

### 2.1 Componentes

| Capa             | Tecnología               | Función                                                        |
|------------------|--------------------------|----------------------------------------------------------------|
| Modelo           | LightGBM + Optuna        | Predicción binaria de compra por (cliente, día)                |
| Explicabilidad   | SHAP                     | Interpretación global y por instancia                          |
| Storage          | Parquet en S3-compatible | Tabla de predicciones, leída por el agente                     |
| Engine analítico | DuckDB embebido          | Consultas SQL sub-segundo sobre Parquet (no requiere servidor) |
| Agente IA        | Claude Sonnet + tool use | Traduce preguntas en filtros estructurados                     |
| UI               | Streamlit                | Chat, dashboard y métricas del modelo                          |

|           |        |                              |
|-----------|--------|------------------------------|
| Container | Docker | Portabilidad cloud-agnóstica |
|-----------|--------|------------------------------|

## 2.2 Diseño cloud-agnóstico

La arquitectura se ejecuta sin cambios en las tres principales nubes. La portabilidad se logra evitando servicios propietarios y favoreciendo estándares abiertos:

| Componente               | DigitalOcean           | AWS                      | GCP                              |
|--------------------------|------------------------|--------------------------|----------------------------------|
| Object storage           | Spaces (S3-compatible) | S3                       | GCS (vía HMAC, equivalente a S3) |
| Compute                  | App Platform           | ECS Fargate o App Runner | Cloud Run                        |
| LLM                      | Anthropic API directa  | Anthropic API directa    | Anthropic API directa            |
| Cache (opcional)         | Managed Redis          | ElastiCache              | Memorystore                      |
| BD relacional (opcional) | Managed Postgres       | RDS                      | Cloud SQL                        |

El switch de proveedor implica únicamente cambiar variables en `.env`, el código aplicativo es idéntico.

## 2.3 Tool-use estructurado vs. Text-to-SQL

El agente **no escribe SQL libre**. En lugar de eso, expone tres funciones estructuradas:

- `query_predictions(filters, order_by, limit, columns)`
- `aggregate_predictions(group_by, aggregations, filters)`
- `schema_info()`

El LLM emite filtros en formato JSON. Estos se validan contra una **whitelist de columnas y operadores** y se traducen a SQL parametrizado en DuckDB. Esto:

- Elimina el riesgo de SQL injection (en cualquier modalidad).
- Hace la solución **predecible y testeable**.
- Es casi tan flexible como text-to-SQL para los casos de uso comerciales.

# 3. Metodología

## 3.1 Definición del problema

- Granularidad:** una fila igual a una visita de un cliente en un día específico.
- Target:** `incidencia_compra`, valores en {0, 1}.
- Tarea:** clasificación binaria.
- Volumen:** 58,693 visitas, 500 clientes únicos, 730 días (aprox. 2 años).
- Distribución del target:** 24.94% de positivos (desbalance moderado).

### 3.2 Pipeline

CSV crudo ■ ■■ EDA (11 figuras y reporte en docs/eda/REPORTE\_EDA.md) ■ ■■ Feature Eng. (43 features causales y segmentación K-Means; ■ sin leakage: solo info de días anteriores) ■ ■■ Train (Split temporal train/val/test = 70/15/15) ■ 1. LogReg baseline ■ 2. LightGBM + Optuna (30 trials, optimiza AUC val) ■ ■■ Explain (SHAP, lift curve, calibration, decile table) ■ ■■ Score (Predicciones por cliente y día en Parquet, consultable por el agente vía DuckDB)

### 3.3 Feature engineering causal

Para evitar **data leakage**, todas las features históricas se calculan usando únicamente los datos con `dia_visita < día actual` del mismo cliente:

| Familia              | Features                                                                                                       | Descripción                                       |
|----------------------|----------------------------------------------------------------------------------------------------------------|---------------------------------------------------|
| RFM                  | prior_visits,<br>prior_purchases,<br>prior_buy_rate, prior_qty,<br>prior_avg_qty_per_purchase,<br>recency_days | Recencia, frecuencia, monto histórico             |
| Lealtad              | loyalty_b{1..5},<br>loyal_brand_id                                                                             | % histórico de compras por marca; marca dominante |
| Sensibilidad a promo | buy_rate_with_promo,<br>buy_rate_no_promo,<br>promo_uplift                                                     | Cómo responde el cliente a promos históricamente  |
| Precio relativo      | rel_price_b{1..5},<br>min_rel_price_today,<br>loyal_brand_rel_price                                            | Precio actual vs. promedio histórico              |
| Estado del día       | any_promo_today,<br>pct_brands_on_promo,<br>precio_marca_{1..5},<br>promo_marca_{1..5}                         | Variables de la visita actual                     |
| Demografía           | edad, ingreso_anual, genero,<br>estado_civil,<br>nivel_educacion, ocupacion                                    | Estáticas por cliente                             |
| Contexto             | loyal_brand_on_promo,<br>ultima_marca_comprada,<br>ultima_cantidad_comprada                                    | Interacciones                                     |

**Validación de no-leakage:** en la primera visita de cada cliente, todas las features `prior_*` valen 0 y `recency_days` = -1 (sentinel). Validado programáticamente.

### 3.4 Segmentación de clientes

K-Means (k=4) sobre features agregadas a nivel cliente: `buy_rate`, `total_purchases`, `avg_qty_per_purchase`, `edad`, `ingreso_anual`. Etiquetas heurísticas:

| Segmento               | n   | Buy rate real | Interpretación                       |
|------------------------|-----|---------------|--------------------------------------|
| Leales premium         | 47  | 59.6%         | Alta frecuencia e ingreso alto       |
| Cazadores de oferta    | 45  | 28.7%         | Frecuencia media, sensibles a precio |
| Compradores moderados  | 139 | 22.0%         | Comportamiento promedio              |
| Visitantes ocasionales | 269 | 17.7%         | Baja frecuencia                      |

**Nota:** la segmentación se computa sobre todo el periodo y se usa solo como feature para que el agente filtre (no como input del modelo, para no introducir leakage).

### 3.5 Validación temporal

Crítica para evitar leakage en la evaluación:

| Split      | Días      | Filas  |
|------------|-----------|--------|
| Train      | 1 a 509   | 41,061 |
| Validación | 510 a 619 | 8,433  |
| Test       | 620 a 730 | 9,199  |

### 3.6 Modelos entrenados

**Baseline, Logistic Regression:** - `class_weight=balanced` para mitigar desbalance. - `StandardScaler` en numéricas, categóricas como int.

**LightGBM (modelo final):** - Boosting GBDT, manejo nativo de categóricas. - Tuning con Optuna (30 trials, dirección igual a maximizar AUC val). - Early stopping con paciencia de 50 rondas. - Hiperparámetros optimizados: `num_leaves`, `max_depth`, `learning_rate`, `feature_fraction`, `bagging_fraction`, `min_child_samples`, `lambda_l1`, `lambda_l2`.

## 4. Resultados

### 4.1 Métricas de modelo (test set)

| Métrica | LogReg | LightGBM     |
|---------|--------|--------------|
| AUC-ROC | 0.673  | <b>0.684</b> |

|                       |       |              |
|-----------------------|-------|--------------|
| PR-AUC                | 0.458 | 0.457        |
| Log loss              | 0.572 | <b>0.521</b> |
| Brier score           | 0.190 | <b>0.170</b> |
| <b>Lift @ top 10%</b> | 2.36  | <b>2.40</b>  |
| Lift @ top 20%        | 1.87  | 1.90         |
| Lift @ top 30%        | 1.66  | 1.63         |

## 4.2 Análisis de deciles

| Decil               | n     | Score promedio | Tasa real    | Lift vs. base     |
|---------------------|-------|----------------|--------------|-------------------|
| <b>D1 (top 10%)</b> | 5,870 | 0.500          | <b>69.6%</b> | <b>2.40 veces</b> |
| D2                  | 5,869 | 0.334          | 42.7%        | 1.40 veces        |
| D3                  | 5,869 | 0.279          | 31.7%        | 1.10 veces        |
| D4                  | 5,869 | 0.246          | 24.7%        | 1.07 veces        |
| D5                  | 5,869 | 0.226          | 20.1%        | 0.90 veces        |
| D10 (bottom 10%)    | 5,870 | 0.162          | 7.0%         | 0.55 veces        |

**Lectura:** enviando una campaña al top 10% scoreado, **70% de ellos compran**, frente al 25% en la población general (2.4 veces la tasa esperada). Si se extiende al top 20%, se captura aprox. 38% del total de compras llamando solo al 20% de los clientes.

## 4.3 Calibración

El modelo está bien calibrado tras Optuna: las probabilidades predichas por decil (0.50 en D1, 0.16 en D10) son consistentes con las tasas reales (70% en D1, 7% en D10). Brier score igual a 0.170 vs. 0.187 baseline trivial (predecir prior).

## 4.4 Explicabilidad (SHAP)

Top features por impacto promedio: 1. `prior_buy_rate` (correlación con target igual a +0.38) 2. `prior_purchases` (+0.28) 3. `recency_days` (-0.16: más reciente, más probable) 4. `min_rel_price_today` (-0.06: precios más bajos hoy, más probable) 5. `any_promo_today` (+0.06) 6. `loyal_brand_on_promo`, `loyal_brand_rel_price` (interacciones cliente y día)

**Insight de negocio:** la mayor señal predictiva proviene del comportamiento histórico del cliente; las features demográficas aportan poco. Esto valida el enfoque de propensión por visita (vs. por cliente estático).

## 5. Agente conversacional

## 5.1 Diseño

```
Usuario: "Dame los 20 clientes top de Leales premium con score mayor a 0.5" ■ ▼ Claude (sonnet-4-6) interpreta y emite tool call: { "name": "query_predictions", "input": { "filters": [ {"column": "cluster_label", "operator": "=", "value": "Leales premium"}, {"column": "score_compra", "operator": ">", "value": 0.5} ], "order_by": [{"column": "score_compra", "direction": "desc"}], "limit": 20 } } ■ ▼ Validación whitelist, luego SQL parametrizado, luego DuckDB sobre Parquet (S3, Spaces o GCS) ■ ▼ Resultados de vuelta al LLM, que redacta una respuesta en lenguaje natural
```

## 5.2 Casos de uso soportados

- Listar top-K clientes según múltiples filtros (segmento, edad, ingreso, decil, marca leal).
- Agregaciones por grupo (score promedio por segmento, # clientes en decil top con promo).
- Validación del modelo (comparar score predicho vs. tasa real por subconjunto).
- Análisis de campañas (qué % de compras se capturan en el top-N).

# 6. Captura de valor en el negocio

## 6.1 Áreas impactadas

| Área                  | Impacto                                              | KPI                                                   |
|-----------------------|------------------------------------------------------|-------------------------------------------------------|
| Marketing dirigido    | Reducir costo de campañas contactando solo al top-K  | Costo de campaña (menos 50% al cortar bottom-50%)     |
| Pricing y promociones | Identificar clientes con alta sensibilidad a promo   | Lift incremental por promo personalizada              |
| Reactivación          | Detectar clientes activos con baja propensión actual | Tasa de reactivación, # clientes recuperados          |
| Operación comercial   | Auto-servicio para análisis ad-hoc                   | Tiempo de respuesta a preguntas (de horas a segundos) |
| Pricing dinámico      | Identificar elasticidad por segmento                 | Margen por unidad por segmento                        |

## 6.2 Estimación de valor (top-down, conservadora)

**Asunción:** 500 clientes, aprox. 25% conversión histórica, ticket promedio aprox. 3 unidades a precio promedio S/2. Universo anual de aprox. 25,000 visitas con 6,250 compras por aprox. S/6 igual a aprox. S/37.5k de revenue baseline en 2 años.

**Escenario campaña dirigida al top-20% por score** (en lugar de campaña masiva al 100%): - Costo de contacto cae **80%**. - Captura de compras: aprox. **38%** del total (curva de lift). - Si el costo de contactar al 100% es S/X, el ahorro es 0.80 por S/X manteniendo 38% de la efectividad, lo que da una rentabilidad por contacto aprox. 5 veces.

**Escenario activación de "Cazadores de oferta"** con promociones personalizadas: - 45 clientes con frecuencia aprox. 25%, lo que produce aprox. 3.4 visitas por mes. - Si la promo personalizada incrementa buy rate 5pp absolutos (de 29% a 34%), se generan aprox. 7 compras adicionales por mes en este segmento.

6.3 KPIs propuestos

| KPI                                                                            | Frecuencia | Meta inicial                                      |
|--------------------------------------------------------------------------------|------------|---------------------------------------------------|
| Lift de conversión campañas vs. control random                                 | Mensual    | mayor o igual a 2.0 veces                         |
| Costo por compra incremental (CAC marginal)                                    | Mensual    | menos 40% vs. baseline                            |
| Tasa de reactivación (clientes inactivos más de 30 días que vuelven a comprar) | Trimestral | más 10pp                                          |
| Tiempo medio de resolución de queries comerciales (uso del agente)             | Mensual    | menor a 2 min                                     |
| Calibración del modelo (Brier score en producción)                             | Mensual    | menor o igual a 0.18                              |
| Drift de scores vs. baseline                                                   | Semanal    | Alerta si la distribución de D1 cambia más de 15% |

7. Cronograma propuesto

| Semana | Tarea                                           |
|--------|-------------------------------------------------|
| 1      | EDA y diseño de features causales               |
| 2      | Modelado (baseline + LightGBM + tuning)         |
| 3      | Explicabilidad, métricas de negocio y agente IA |
| 4      | UI Streamlit, despliegue cloud y documentación  |

8. Próximos pasos y extensiones

- 1. **Modelo multiclase de marca:** predecir cuál marca elige el cliente cuando compra.
- 2. **Re-entrenamiento periódico** automatizado con Airflow, Prefect o Cloud Scheduler.
- 3. **A/B testing framework** para validar el lift en producción contra grupo control.
- 4. **Monitoreo de drift** con Evidently o Whylabs.
- 5. **Feature de engagement digital** si llega data de canal online.

6. **Pricing optimizer** sobre el output del modelo (ej: simular impacto de cambio de precio en propensión por segmento).