

Reporte EDA, Ferreycorp · Propensión de Compra

1. Visión general del dataset


Métrica	Valor
Filas (visitas)	58,693
Columnas	23
Cientes únicos	500
Rango temporal	día 1 al día 730 (aprox. 2 años)
Visitas promedio por cliente	117.4
Compras promedio por cliente	29.3
Tasa de conversión global	24.94%
Valores nulos	0

La granularidad es **una fila igual a una visita de un cliente en un día**. El target `incidencia_compra` está moderadamente desbalanceado (aprox. 25% positivos), pero suficientemente representado como para no requerir oversampling agresivo.

2. Distribución demográfica


Los 500 clientes son adultos entre 18 y 75 años (mediana aprox. 36), con ingresos anuales entre 38k y 309k. Nivel educativo y ocupación están codificados como ordinales o categóricas.

Distribución demográfica de los 500 clientes únicos




3. Comportamiento de visita y compra

Los clientes son recurrentes: en promedio 117 visitas en 2 años, de las cuales 29 resultan en compra. Esto valida la formulación de **propensión por visita** sobre propensión por cliente, ya que hay suficiente densidad temporal por individuo.




4. Marcas y participación de mercado

Las 5 marcas tienen participaciones muy distintas, dominadas por **Marca 5 (34.0%)** y **Marca 2 (31.0%)**. La Marca 3 es claramente nicho (5.7%). Esto sugiere que un modelo multiclase de marca tendría clases desbalanceadas, conviene tenerlo presente.




5. Precios y promociones


Los precios fluctúan en el tiempo, no son estáticos. Esto es **una palanca de pricing real**: si entendemos elasticidad por marca, podemos sugerir cuándo bajar precio para activar clientes de baja propensión.



Lift de promoción: la tasa de compra con al menos una marca en promo es **26.9%** vs. **21.8%** sin promo (lift 23.1%). Las promociones sí mueven la aguja, son una feature de primer orden para el modelo.




6. Demografía vs. tasa de compra




Hay diferencias entre rangos de edad y quintiles de ingreso, aunque ninguna es dramática. Las features demográficas aportan, pero la señal principal está en el comportamiento histórico y las palancas comerciales (precio y promo).

7. Sensibilidad a precio




Cuando un cliente compra, una proporción significativa elige la marca más barata disponible. Esto refuerza la importancia de features como **precio relativo** y **descuento vs. promedio histórico**.

8. Correlaciones



Sin correlaciones bivariadas extremadamente fuertes con el target. Esto es típico en problemas de propensión: la señal viene de **interacciones** (ej. cliente, precio y promo), donde los modelos basados en árboles (LightGBM) funcionan mejor que los modelos lineales.

9. Lealtad de marca



Aproximadamente **89% de los clientes** concentran más del 50% de sus compras en una sola marca. Esto valida construir feature de **lealtad histórica** y posiblemente segmentar clientes en clústeres (leales vs. cazadores de oferta).

10. Hallazgos clave para modelado

1. **Granularidad correcta:** visita-cliente, modelo binario con `incidencia_compra` como target.
2. **Sin nulos**, no se requiere imputación.
3. **Variables categóricas:** `genero`, `estado_civil`, `nivel_educacion`, `ocupacion`, `id_marca`.
4. **Variables numéricas:** `edad`, `ingreso_anual`, precios y promos por marca.
5. **Feature engineering crítico** (debe calcularse con ventana causal, solo con datos `dia < dia_visita`):
6. **RFM:** recencia, frecuencia, monto promedio.
7. **Lealtad:** % histórico de compras por marca por cliente.
8. **Sensibilidad a promo:** tasa de compra del cliente cuando hay promo vs. cuando no.
9. **Precio relativo:** precio actual de cada marca dividido por el precio promedio histórico.
10. **Última marca y última cantidad:** ya vienen en el dataset.
11. **Validación temporal:** split por `dia_visita` (no random) para evitar leakage.
12. **Modelo principal:** LightGBM (maneja categóricas, captura interacciones, es rápido).
13. **Métrica de negocio:** Lift @ top-K, más útil que accuracy para campañas dirigidas.