

# Modelo de Propensión de Compra + Agente IA Conversacional

---

Caso técnico Ferreycorp · Abril 2026

## Objetivos

### Objetivo de negocio

Predecir, en cada visita, qué clientes comprarán, y permitir al equipo comercial **filtrar y explorar las predicciones en lenguaje natural**.

### Objetivos técnicos

- **AUC-ROC  $\geq 0.65$  · Lift @ top-10%  $\geq 2.0$**
- Modelo explicable globalmente y por cliente (SHAP)
- Agente conversacional con acceso  $< 100$  ms a las predicciones
- Arquitectura **portable cloud** (DigitalOcean / AWS / GCP)

### Stack

Python · LightGBM · Optuna · SHAP · DuckDB · Anthropic API · Streamlit · Docker

# Cronograma de trabajo

| Semana | Entregable                                    | Resultado                                     |
|--------|-----------------------------------------------|-----------------------------------------------|
| S1     | EDA + diseño de features causales             | 11 figuras + reporte · 43 features definidas  |
| S2     | Modelado: baseline + LightGBM + tuning Optuna | AUC test 0.684 · lift 2.40×                   |
| S3     | Explicabilidad (SHAP) + agente IA + UI        | Streamlit con chat funcional                  |
| S4     | Despliegue cloud + documentación + slides     | Specs DO/AWS/GCP · doc técnico · presentación |

## Hitos clave del proyecto

- ■ **EDA reproducible**: script Python que regenera todas las figuras
- ■■ **Features causales**: validadas sin leakage temporal
- ■ **Modelo bien calibrado**: Brier score 0.170
- ■ **Agente seguro**: tool use estructurado, no text-to-SQL libre
- ■■ **Cloud-agnóstico**: DO / AWS / GCP sin tocar código

# Análisis Exploratorio (EDA)

## Dataset

58,693 visitas · 500 clientes únicos · 730 días (~2 años) · 5 marcas · 25% de tasa de conversión global · sin valores nulos

## Hallazgos clave

| Hallazgo                                                | Implicación para el modelo                          |
|---------------------------------------------------------|-----------------------------------------------------|
| 89% de clientes concentran >50% de compras en una marca | Lealtad histórica como feature top                  |
| +23% de lift cuando hay promo (26.9% vs 21.8%)          | Promo es palanca de primer orden                    |
| Marcas 5 y 2 dominan (65%) · Marca 3 nicho (5.7%)       | Multiclase de marca tendría desbalance              |
| Precios fluctúan en el tiempo                           | Feature de precio relativo viable                   |
| Cliente promedio: 117 visitas / 29 compras              | Densidad temporal suficiente para features causales |

# Metodología de la solución

EDA, Feature Engineering Causal, Train Temporal Split, Tuning, Score, Agent

## Features (43 totales) sin leakage

- **RFM**: recencia, frecuencia, ticket promedio histórico
- **Lealtad**: % histórico de compras por marca (5 columnas)
- **Sensibilidad personal a promo**: tasa de compra con/sin promo, uplift
- **Precio relativo**: precio actual vs. promedio histórico por marca
- **Demografía + cluster**: K-Means k=4 para segmentación de clientes

## Modelos entrenados


| Modelo              | Rol                                           |
|---------------------|-----------------------------------------------|
| Logistic Regression | Baseline interpretable, class_weight=balanced |
| LightGBM + Optuna   | Modelo final, 30 trials de tuning bayesiano   |

**Validación:** split temporal · train (días 1-509) · val (510-619) · test (620-730)

## Métricas de negocio (no solo accuracy)

AUC-ROC · PR-AUC · Brier (calibración) · **Lift @ top-K** (KPI de campañas)

# Arquitectura cloud-agnóstica



## Mismo Docker, tres nubes

| Componente     | DigitalOcean  | AWS           | GCP           |
|----------------|---------------|---------------|---------------|
| Object storage | Spaces        | S3            | GCS (HMAC)    |
| Compute        | App Platform  | ECS Fargate   | Cloud Run     |
| LLM            | Anthropic API | Anthropic API | Anthropic API |

## Seguridad del agente

El LLM **NO** escribe **SQL libre**, emite filtros estructurados que se validan contra una whitelist de columnas/operadores antes de generar SQL parametrizado.

# Resultados

## Métricas test (LightGBM)

| AUC-ROC | Lift @ top 10% | Lift @ top 20% | Brier (calibración) |
|---------|----------------|----------------|---------------------|
| 0.684   | 2.40×          | 1.90×          | 0.170               |

## Análisis por decil, el dato que cuenta al negocio

| Decil            | n     | Score predicho | Tasa real | Lift vs base |
|------------------|-------|----------------|-----------|--------------|
| D1 (top 10%)     | 5,870 | 0.50           | 69.6%     | 2.40×        |
| D2               | 5,869 | 0.33           | 42.7%     | 1.40×        |
| D5               | 5,869 | 0.23           | 20.1%     | 0.90×        |
| D10 (bottom 10%) | 5,870 | 0.16           | 7.0%      | 0.55×        |

Llamando solo al **top 20%**, se capturan aprox. **38% de las compras totales**.

### Top features (SHAP)

prior\_buy\_rate · prior\_purchases · recency\_days · min\_rel\_price\_today · loyal\_brand\_on\_promo

# Captura de valor en el negocio

## Áreas de impacto y KPIs

| Área                  | Palanca                          | KPI clave                            |
|-----------------------|----------------------------------|--------------------------------------|
| ■ Marketing dirigido  | Cortar contactos a bottom-50%    | Costo por compra: <b>-50%</b>        |
| ■■ Pricing & promo    | Personalizar promos por segmento | Lift incremental por promo           |
| ■■ Reactivación       | Detectar baja-propensión activa  | Tasa reactivación: <b>+10pp</b>      |
| ■ Operación comercial | Self-service vía chat IA         | Time-to-insight: de horas a segundos |

## Modelo económico, campaña al top-20% por score

- ■ **80%** menos costo de contacto vs. campaña masiva
- ■ Mantiene **38%** de la efectividad de la campaña masiva
- Rentabilidad por contacto aprox. **5 veces** vs. baseline

## Roadmap de extensiones

Modelo multiclase de marca · A/B testing en producción · monitoreo de drift · pricing optimizer · re-entrenamiento automatizado