

Modelo de Propensión de Compra + Agente IA Conversacional

Caso técnico Ferreycorp · Abril 2026

Objetivos

Objetivo de negocio

Predecir, en cada visita, qué clientes comprarán — y permitir al equipo comercial **filtrar y explorar las predicciones en lenguaje natural**.

Objetivos técnicos

- **AUC-ROC ≥ 0.65 · Lift @ top-10% ≥ 2.0**
- Modelo explicable globalmente y por cliente (SHAP)
- Agente conversacional con acceso < 100 ms a las predicciones
- Arquitectura **portable cloud** (DigitalOcean / AWS / GCP)

Stack

Python · LightGBM · Optuna · SHAP · DuckDB · Anthropic API · Streamlit · Docker

Cronograma de trabajo

Semana	Entregable	Resultado
S1	EDA + diseño de features causales	11 figuras + reporte · 43 features definidas
S2	Modelado: baseline + LightGBM + tuning Optuna	AUC test 0.684 · lift 2.40×
S3	Explicabilidad (SHAP) + agente IA + UI	Streamlit con chat funcional
S4	Despliegue cloud + documentación + slides	Specs DO/AWS/GCP · doc técnico · presentación

Hitos clave del proyecto

- ■ **EDA reproducible**: script Python que regenera todas las figuras
- ■■ **Features causales**: validadas sin leakage temporal
- ■ **Modelo bien calibrado**: Brier score 0.170
- ■ **Agente seguro**: tool use estructurado, no text-to-SQL libre
- ■■ **Cloud-agnóstico**: DO / AWS / GCP sin tocar código

Análisis Exploratorio (EDA)

Dataset

58,693 visitas · 500 clientes únicos · 730 días (~2 años) · 5 marcas · 25% de tasa de conversión global · sin valores nulos

Hallazgos clave

Hallazgo	Implicación para el modelo
89% de clientes concentran >50% de compras en una marca	Lealtad histórica → feature top
+23% de lift cuando hay promo (26.9% vs 21.8%)	Promo es palanca de primer orden
Marcas 5 y 2 dominan (65%) · Marca 3 nicho (5.7%)	Multiclase de marca tendría desbalance
Precios fluctúan en el tiempo	Feature de precio relativo viable
Cliente promedio: 117 visitas / 29 compras	Densidad temporal suficiente para features causales

Metodología de la solución

EDA → Feature Engineering Causal → Train Temporal Split → Tuning → Score → Agent

Features (43 totales) — sin leakage

- **RFM**: recencia, frecuencia, ticket promedio histórico
- **Lealtad**: % histórico de compras por marca (5 columnas)
- **Sensibilidad personal a promo**: tasa de compra con/sin promo, uplift
- **Precio relativo**: precio actual vs. promedio histórico por marca
- **Demografía + cluster**: K-Means k=4 para segmentación de clientes

Modelos entrenados

Modelo	RoI
Logistic Regression	Baseline interpretable, class_weight=balanced
LightGBM + Optuna	Modelo final, 30 trials de tuning bayesiano

Validación: split temporal · train (días 1-509) · val (510-619) · test (620-730)

Métricas de negocio (no solo accuracy)

AUC-ROC · PR-AUC · Brier (calibración) · **Lift @ top-K** (KPI de campañas)



Seguridad del agente

El LLM **NO escribe SQL libre** — emite filtros estructurados que se validan contra una whitelist de columnas/operadores antes de generar SQL parametrizado.

Resultados

Métricas test (LightGBM)

AUC-ROC	Lift @ top 10%	Lift @ top 20%	Brier (calibración)
0.684	2.40×	1.90×	0.170

Análisis por decil — el dato que cuenta al negocio

Decil	n	Score predicho	Tasa real	Lift vs base
D1 (top 10%)	5,870	0.50	69.6%	2.40×
D2	5,869	0.33	42.7%	1.40×
D5	5,869	0.23	20.1%	0.90×
D10 (bottom 10%)	5,870	0.16	7.0%	0.55×

→ Llamando solo al **top 20%**, capturas **~38% de las compras totales**.

Top features (SHAP)

prior_buy_rate · prior_purchases · recency_days · min_rel_price_today · loyal_brand_on_promo

Captura de valor en el negocio

Áreas de impacto y KPIs

Área	Palanca	KPI clave
■ Marketing dirigido	Cortar contactos a bottom-50%	Costo por compra: -50%
■■ Pricing & promo	Personalizar promos por segmento	Lift incremental por promo
■■ Reactivación	Detectar baja-propensión activa	Tasa reactivación: +10pp
■ Operación comercial	Self-service vía chat IA	Time-to-insight: horas → segundos

Modelo económico — campaña al top-20% por score

- ■ **80%** menos costo de contacto vs. campaña masiva
- ■ Mantiene **38%** de la efectividad de la campaña masiva
- → Rentabilidad por contacto **~5x** vs. baseline

Roadmap de extensiones

Modelo multiclase de marca · A/B testing en producción · monitoreo de drift · pricing optimizer · re-entrenamiento automatizado