

Modelo de Propensión de Compra + Agente IA Conversacional

Caso técnico Ferreycorp · Abril 2026

Objetivos

Objetivo de negocio

Predecir, en cada visita, qué clientes comprarán — y permitir al equipo comercial **filtrar y explorar las predicciones en lenguaje natural**.

Objetivos técnicos

- **AUC-ROC ≥ 0.65 · Lift @ top-10% ≥ 2.0**
- Modelo explicable globalmente y por cliente (SHAP)
- Agente conversacional con acceso < 100 ms a las predicciones
- Arquitectura **portable cloud** (DigitalOcean / AWS / GCP)

Stack

Python · LightGBM · Optuna · SHAP · DuckDB · Anthropic API · Streamlit · Docker

Cronograma de trabajo

Semana	Entregable	Resultado
S1	EDA + diseño de features causales	11 figuras + reporte · 43 features definidas
S2	Modelado: baseline + LightGBM + tuning Optuna	AUC test 0.684 · lift 2.40×
S3	Explicabilidad (SHAP) + agente IA + UI	Streamlit con chat funcional
S4	Despliegue cloud + documentación + slides	Specs DO/AWS/GCP · doc técnico · presentación

Hitos clave del proyecto

- ■ **EDA reproducible**: script Python que regenera todas las figuras
- ■■ **Features causales**: validadas sin leakage temporal
- ■ **Modelo bien calibrado**: Brier score 0.170
- ■ **Agente seguro**: tool use estructurado, no text-to-SQL libre
- ■■ **Cloud-agnóstico**: DO / AWS / GCP sin tocar código

Análisis Exploratorio (EDA)

Dataset

58,693 visitas · 500 clientes únicos · 730 días (~2 años) · 5 marcas · 25% de tasa de conversión global · sin valores nulos

Hallazgos clave

Hallazgo	Implicación para el modelo
89% de clientes concentran >50% de compras en una marca	Lealtad histórica → feature top
+23% de lift cuando hay promo (26.9% vs 21.8%)	Promo es palanca de primer orden
Marcas 5 y 2 dominan (65%) · Marca 3 nicho (5.7%)	Multiclase de marca tendría desbalance
Precios fluctúan en el tiempo	Feature de precio relativo viable
Cliente promedio: 117 visitas / 29 compras	Densidad temporal suficiente para features causales

Metodología de la solución

EDA → Feature Engineering Causal → Train Temporal Split → Tuning → Score → Agent

Features (43 totales) — sin leakage

- **RFM**: recencia, frecuencia, ticket promedio histórico
- **Lealtad**: % histórico de compras por marca (5 columnas)
- **Sensibilidad personal a promo**: tasa de compra con/sin promo, uplift
- **Precio relativo**: precio actual vs. promedio histórico por marca
- **Demografía + cluster**: K-Means k=4 para segmentación de clientes

Modelos entrenados


Modelo	RoI
Logistic Regression	Baseline interpretable, class_weight=balanced
LightGBM + Optuna	Modelo final, 30 trials de tuning bayesiano

Validación: split temporal · train (días 1-509) · val (510-619) · test (620-730)

Métricas de negocio (no solo accuracy)

AUC-ROC · PR-AUC · Brier (calibración) · **Lift @ top-K** (KPI de campañas)

Arquitectura cloud-agnóstica



Mismo Docker, tres nubes

Componente	DigitalOcean	AWS	GCP
Object storage	Spaces	S3	GCS (HMAC)
Compute	App Platform	ECS Fargate	Cloud Run
LLM	Anthropic API	Anthropic API	Anthropic API

Seguridad del agente

El LLM **NO escribe SQL libre** — emite filtros estructurados que se validan contra una whitelist de columnas/operadores antes de generar SQL parametrizado.

Resultados

Métricas test (LightGBM)

AUC-ROC	Lift @ top 10%	Lift @ top 20%	Brier (calibración)
0.684	2.40×	1.90×	0.170

Análisis por decil — el dato que cuenta al negocio

Decil	n	Score predicho	Tasa real	Lift vs base
D1 (top 10%)	5,870	0.50	69.6%	2.40×
D2	5,869	0.33	42.7%	1.40×
D5	5,869	0.23	20.1%	0.90×
D10 (bottom 10%)	5,870	0.16	7.0%	0.55×

→ Llamando solo al **top 20%**, capturas **~38% de las compras totales**.

Top features (SHAP)

prior_buy_rate · prior_purchases · recency_days · min_rel_price_today · loyal_brand_on_promo

Captura de valor en el negocio

Áreas de impacto y KPIs

Área	Palanca	KPI clave
■ Marketing dirigido	Cortar contactos a bottom-50%	Costo por compra: -50%
■■ Pricing & promo	Personalizar promos por segmento	Lift incremental por promo
■■ Reactivación	Detectar baja-propensión activa	Tasa reactivación: +10pp
■ Operación comercial	Self-service vía chat IA	Time-to-insight: horas → segundos

Modelo económico — campaña al top-20% por score

- ■ **80%** menos costo de contacto vs. campaña masiva
- ■ Mantiene **38%** de la efectividad de la campaña masiva
- → Rentabilidad por contacto **~5x** vs. baseline

Roadmap de extensiones

Modelo multiclase de marca · A/B testing en producción · monitoreo de drift · pricing optimizer · re-entrenamiento automatizado